

Documentação dos Pipelines ETL — Cotação x Salesforce

⚠ Atenção antes de executar

Todos os três scripts fazem referência a caminhos fixos de pastas no computador original (stenz). **Antes de rodar qualquer um dos códigos**, é necessário alterar esses caminhos para o local onde as pastas de dados estiverem salvas na sua máquina.

Caminho de entrada (onde ficam os arquivos originais .xlsx):

```
C:\Users\stenz\Documents\InterCement\Base Dados\
```

Caminho de saída (onde os arquivos processados serão salvos):

```
C:\Users\stenz\Documents\InterCement\Base Result\
```

Esses caminhos aparecem nas variáveis `caminho`, `caminho_saida` e `PASTA_BASE` dentro dos scripts. Basta substituir pelo diretório correto no seu ambiente, mantendo a estrutura de subpastas (Base Dados para entrada e Base Result para saída/entrada intermediária).

Ordem de execução

Os três scripts formam um pipeline encadeado e **precisam ser executados na seguinte ordem**, pois cada um depende do resultado do anterior:

1. **ETL_SalesForce_Pipeline.py** → gera `SalesForce_Result.xlsx`
2. **ETL_Cotacao_Pipeline.py** → gera `Catacao_Result.xlsx`
3. **Concolida_Cotacao_SalesForce.py** → consome os dois arquivos acima e gera `BaseFinal_Cotacao_SalesForce.xlsx`

Abaixo, a documentação detalhada de cada script, na mesma ordem.

1. ETL_SalesForce_Pipeline.py

Objetivo

Carregar a base bruta do Salesforce (`SalesForce_CASE.xlsx`), tratar e padronizar os dados, remover duplicidades e linhas inválidas, e exportar o resultado limpo em `SalesForce_Result.xlsx`.

Arquivos

Tipo	Caminho	Observação
Entrada	Base Dados\SalesForce_CASE.xlsx	Arquivo bruto do Salesforce
Saída	Base Result\SalesForce_Result.xlsx	Arquivo tratado
Log	pipeline_salesforce.log	Gerado na pasta de execução do script

Colunas com tipo forçado (dtype)

TipoCotação, ID da Cotação, ID da Cotação do SAP, Código do Cliente, Cód. Expedição, Material: Código do material, Meio de Transporte — todas lidas como texto (string).

Funções

- **carregar_arquivo(caminho, dtype_cols)** Lê o Excel de entrada aplicando os tipos definidos em dtype_cols. Registra no log a quantidade de linhas e colunas carregadas.
- **tratar_colunas_texto(df, cols)** Para cada coluna de texto listada, substitui valores nulos ou vazios por "0" e garante o tipo string.
- **tratar_colunas_numericas(df, cols)** Para as colunas Frete Comercial e Chapa, substitui valores nulos ou vazios por 0.0 e converte para float.
- **remover_linhas_vazias(df)** Remove linhas onde todas as colunas estão vazias/nulas. Registra no log quantas linhas foram removidas.
- **remover_duplicados(df, chaves)** Remove linhas duplicadas com base nas chaves ID da Cotação do SAP, Material: Código do material e Cód. Expedição. Registra no log a quantidade de duplicados encontrados.
- **remover_tipo_zero(df)** Remove as linhas em que TipoCotação ficou igual a "0" (ou seja, estava vazio antes do tratamento).
- **filtrar_condicoes(df)** Função de diagnóstico (opcional): identifica linhas em que TipoCotação está vazio e Frete Comercial <= 0 e Chapa <= 0. O resultado não é usado no fluxo principal, apenas registrado/calculado à parte.
- **exportar_excel(df, caminho_saida_base)** Exporta o DataFrame final para Excel, sem timestamp no nome do arquivo.
- **pipeline_salesforce()** Função principal que orquestra todo o fluxo: carrega → trata colunas de texto → trata colunas numéricas → remove linhas vazias → remove duplicados → remove TipoCotação = "0" → (calcula filtro de diagnóstico) → exporta.

Fluxo resumido

SalesForce_CASE.xlsx
→ tratar textos/números
→ remover vazios e duplicados
→ remover TipoCotação = "0"
→ Salesforce_Result.xlsx

2. ETL_Cotacao_Pipeline.py

Objetivo

Carregar a base bruta de Cotações (COTAÇÕES_CASE.xlsx), converter colunas decimais, padronizar o tipo de cotação, verificar duplicidades e exportar o resultado em Catacao_Result.xlsx.

Arquivos

Tipo	Caminho	Observação
Entrada	Base Dados\COTAÇÕES_CASE.xlsx	Lido a partir da linha 3 (header=2)
Saída	Base Result\Catacao_Result.xlsx	Arquivo tratado
Log	pipeline_cotacoes.log	Gerado na pasta de execução do script

Colunas com tipo forçado (dtype)

Status FLUXO SAP*, TipoCotação, ID da Cotação do SAP, Dt. Criação Sol., Status da Cotação, Id Solic. Ajuste, Última Ação em, Cód. Expedição, Região, Gestão de Vendas, Micro Região, Código do Cliente, Material, Embalagem, Cliente Condição, Incoterm — todas lidas como texto (string).

Colunas decimais tratadas

Preço Atual, Preço Proposto, Var. Preço Proposto.

Funções

- **carregar_arquivo(caminho, dtype_cols)** Carrega o Excel pulando as duas primeiras linhas (header=2, ou seja, o cabeçalho real está na 3ª linha) e aplica os tipos definidos.
- **converter_decimal(df, cols)** Converte as colunas de preço para numérico, transformando valores inválidos em NaN (errors="coerce").
- **tratar_tipo_cotacao(df)** Substitui valores vazios da coluna TipoCotação por "Vazio".
- **tratar_decimais_vazios(df, cols)** Substitui valores vazios/nulos nas colunas decimais por 0.
- **verificar_duplicados(df, chaves)** Identifica (sem remover) linhas duplicadas com base em ID da Cotação do SAP, Material e Cód. Expedição. Registra a quantidade encontrada no log, apenas para diagnóstico.
- **exportar_excel(df, caminho_saida_base)** Exporta o DataFrame final para Excel, sem timestamp no nome.
- **pipeline_cotacoes()** Função principal: carrega → converte decimais → trata TipoCotação → trata decimais vazios → verifica duplicados (não remove) → exporta.

Fluxo resumido

COTAÇÕES_CASE.xlsx (header na linha 3)
 → converter preços para numérico
 → tratar TipoCotação vazio → "Vazio"
 → zerar decimais vazios
 → verificar duplicados (diagnóstico)
 → Catacao_Result.xlsx

3. Concolida_Cotacao_SalesForce.py

Objetivo

Unir (LEFT JOIN) as bases já tratadas de Cotação e Salesforce, aplicar a regra de negócio de **janela móvel de 30 dias** para cotações aprovadas e exportar a base final consolidada.

Arquivos

Tipo	Caminho	Observação
Entrada 1	Base Result\Catacao_Result.xlsx	Gerado pelo script 2
Entrada 2	Base Result\SalesForce_Result.xlsx	Gerado pelo script 1
Saída	Base Result\BaseFinal_Cotacao_SalesForce.xlsx	Arquivo final consolidado

Este script depende diretamente dos resultados dos dois scripts anteriores — por isso deve ser executado por último.

Funções

Suporte

- **carregar_excel(caminho)** Carrega um Excel validando previamente se o arquivo existe; levanta erro (FileNotFoundException) caso contrário.
- **padronizar_colunas(df)** Remove espaços extras e quebras de linha dos nomes das colunas.
- **detectar_formato_data(valor)** Função de diagnóstico: identifica, via expressão regular, em qual formato textual uma data está escrita (dd/mm/aaaa, aaaa-mm-dd, etc.), retornando "formato desconhecido" quando não reconhece nenhum padrão.
- **converter_datas(df)** Localiza automaticamente a coluna de data de criação da solicitação (contendo "Criação" e "Sol" no nome), gera uma coluna auxiliar Formato Detectado para diagnóstico, converte a coluna para o tipo data (dayfirst=True) e a renomeia para Dt_Criacao_Sol.

Transformações

- **aplicar_left_join(df_catacao, df_salesforce)** Renomeia Material: Código do material para Material na base Salesforce e faz um LEFT JOIN com a base de Cotação, usando como chave ID da Cotação do SAP, Material e Cód. Expedição. Traz as colunas Frete Comercial e Chapa, preenchendo valores ausentes com 0.
- **calcular_janela_30d(grupo)** Para cada grupo (cliente + material + expedição), ordena por data, desloca (shift) os indicadores de elegibilidade em uma posição, e calcula, em uma janela móvel retroativa de 30 dias:
 - **Qtd_cotacoes_aprovadas_30d**: quantidade de cotações aprovadas elegíveis nos últimos 30 dias (sem contar a linha atual);
 - **Soma_variacao_desconto_30d**: soma da variação de preço proposto elegível nos últimos 30 dias.
- **aplicar_regras_janela(df)** Define a elegibilidade de cada linha como Status da Cotação == "Aprovada" e TipoCotação em ["Banda", "PrecoFixo"]. Agrupa por Código do Cliente, Material e Cód. Expedição, aplica calcular_janela_30d a cada grupo (via laço manual, para preservar as colunas de agrupamento — comportamento necessário a partir do pandas 3.0) e remove as colunas auxiliares usadas no cálculo.

Exportação

- **exportar(df)** Remove a coluna de diagnóstico Formato Detectado (se existir) e exporta o resultado final para BaseFinal_Cotacao_SalesForce.xlsx.

Pipeline principal

- **pipeline_etl()** Orquestra o fluxo completo: carrega as duas bases tratadas → padroniza nomes de colunas → converte datas na base de Cotação → aplica o LEFT JOIN → aplica as regras de janela de 30 dias → exporta o resultado final.


Fluxo resumido

Catacao_Result.xlsx + Salesforce_Result.xlsx
→ padronizar nomes de colunas
→ converter coluna de data (Dt_Criacao_Sol)
→ LEFT JOIN (chave: ID Cotação SAP + Material + Cód. Expedição)
→ calcular janela móvel de 30 dias (por cliente/material/expedição)

- Qtd_cotacoes_aprovadas_30d
- Soma_variacao_desconto_30d

→ BaseFinal_Cotacao_SalesForce.xlsx

Resumo do encadeamento completo



Lembrete final: confira e ajuste os caminhos (Base Dados e Base Result) em cada um dos três scripts antes de executar, conforme indicado no início deste documento.